Visualización de Datos con Python 3.7 y D3.js



Alfonso Neil Jiménez Casallas Ingeniero de sistemas Pontificia Universidad Javeriana

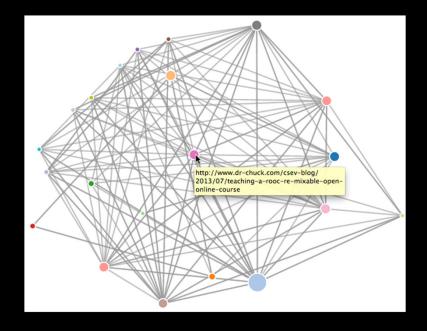
https://github.com/pochito427/ alfonso.jimenez@javeriana.edu.co https://www.linkedin.com/in/alfonso-jimenez-3208a120/



Caso de estudio: Page Rank

- Escribir un rastreador (crawler) simple de página Web
- Calcular una versión simple del algoritmo Page Rank de Google

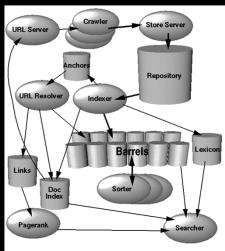




http://www.py4e.com/code3/pagerank.zip

Arquitectura de Motores de Búsqueda

- Rastreo Web (Web Crawling)
- Indexación (Index Building)
- Búsqueda (Searching)



http://infolab.stanford.edu/~backrub/google.html

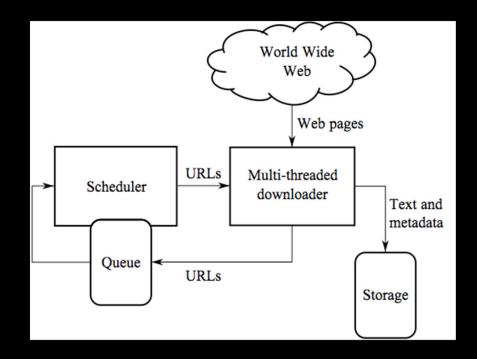
Rastreador Web (Web Crawler)

Programa en computador que comprende la Internet (World Wide Web) de una manera metódica y automatizada. Es usado principalmente para crear una copia de todas las páginas visitadas para procesamiento posterior por un motor de búsquedas que indexará las páginas descargadas para proveer búsquedas rápidas.

http://en.wikipedia.org/wiki/Web_crawler

Web Crawler

- Recupera una página
- Examina la página para encontrar enlaces
- Agrega los enlaces a una lista de sitios "a ser recuperados"
- Repite el proceso...



http://en.wikipedia.org/wiki/Web_crawler

Políticas de Rastreo Web

- Una política de selección que establece cuáles páginas a descargar,
- Una política de re-visitas que establece cuándo verificar cambios a las páginas,
- Una política de cortesía que establece cómo evitar la sobrecarga de sitios Web, y
- Una política de paralelización que establece cómo coordinar rastreadores Web distibuídos

robots.txt

- Una vía para un sitio web de comunicar con los rastreadores web
- Un estándar informal y voluntario



User-agent: *

Disallow: /cgi-bin/

Disallow: /images/

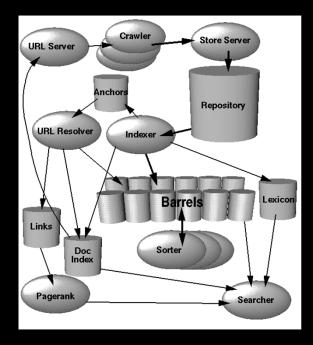
Disallow: /tmp/

Disallow: /private/

http://en.wikipedia.org/wiki/Robots_Exclusion_Standard http://en.wikipedia.org/wiki/Spider_trap

Arquitectura Google

- Web Crawling
- Index Building
- Searching



http://infolab.stanford.edu/~backrub/google.html

Indexación de Búsquedas

La indexación en motores de búsqueda recopila, analiza, y almacena datos para facilitar la recuperación rápida y precisa de información. El propósito de almacenar un índice es optimizar velocidad y rendimiento en encontrar documentos relevantes para una consulta de búsqueda. Sin un índice, el motor de búsquedas exploraría cada documento en el cuerpo, lo cual requiriría un tiempo y poder de cómputo considerables.

http://en.wikipedia.org/wiki/Index_(search_engine)



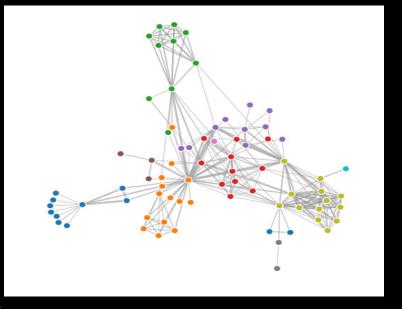
D3.js

"D3.js es una biblioteca de JavaScript para manipular documentos basados en datos. D3 ayuda a dar vida a los datos usando HTML, SVG y CSS. El énfasis de D3 en los estándares web le brinda todas las capacidades de los navegadores modernos sin atarse a un marco propietario, que combina componentes de visualización potentes y un enfoque basado en datos para la manipulación DOM."

https://d3js.org/

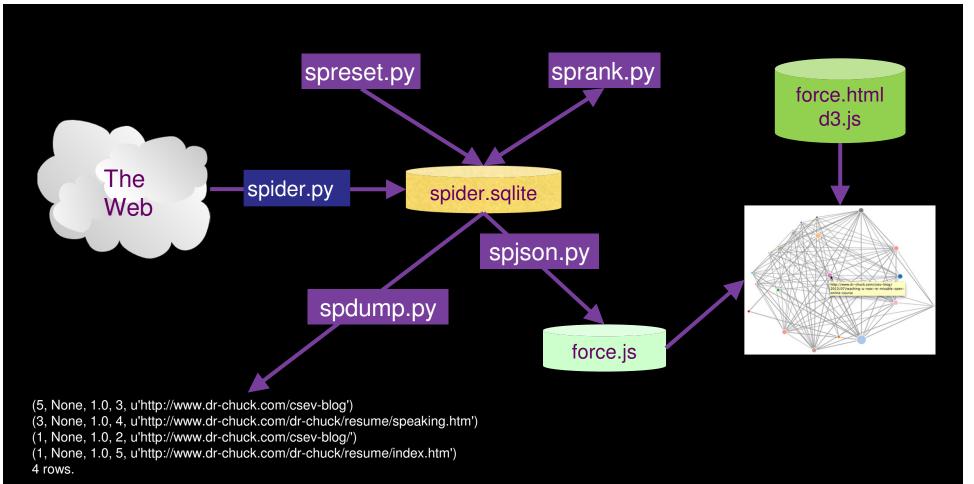
Aplicaciones en grafos dirigidos

Red de coocurrencias entre caracteres en la novela "Los Miserables"



https://observablehq.com/@d3/force -directed-graph



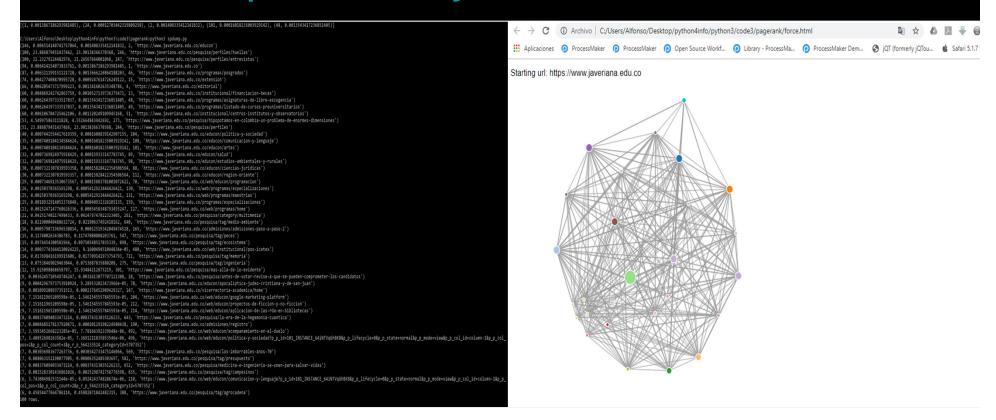


http://www.py4e.com/code3/pagerank.zip

Prueba del PageRank para la URL http://python-data.dr-chuck.net

```
, 0.07935445138366898), (7, 0.15870890276733796), (20, 0.8699724595084117), (137, 0.20363623131344208), (187, 0.20363623131344208)]
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     ← → C ① Archivo | C:/Users/Alfonso/Desktop/python4info/python3/code3/pagerank/force.html
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               Jsers\Alfonso\Desktop\python4info\python3\code3\pagerank>python3 spdump.py
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    Aplicaciones ProcessMaker Proce
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  » Otros marcadores
     2.497974849443514, 2.4979748494434912, 167, http://python-data.dr-chuck.net/known_by_Caitaidh.html')
2.0063914094917608, 2.006391409491774, 217, 'http://python-data.dr-chuck.net/known_by_Peebles.html')
     1.4488960457637058, 1.4480968457636758, 8, 'http://python-data.dr-chuck.net/known_by_Miranne.html')
3.1582031724981374, 3.15820317249812, 545, 'http://python-data.dr-chuck.net/known_by_Joojo.html')
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                Starting url: http://python-data.dr-chuck.net/known_by_42.html
            .2335786943101776, 1.2335786943101805, 424, 'http://python-data.dr-chuck.net/known_by_Data.html')
.6480236818689624, 1.6480236818689495, 730, 'http://python-data.dr-chuck.net/known_by_Charly.html')
       2.885276383045442, 2.855276383845417, 987, 'http://python-data.dr-chuck.net/known_by_Josese.html')
2.2881799417389597, 2.2881799417389543, 1282, 'http://python-data.dr-chuck.net/known_by_Constance.html')
     2.2881/9941238997, 2881/9941399594, 1287, http://gython-data.dr-chuck.net/snown_by_constance.ntml
4.399563440739513, 4.39956344073491, 3142, 'http://gython-data.dr-chuck.net/snown_by_cys.thmli')
1.992283593264014, 1.992283593259935, 2093, 'http://gython-data.dr-chuck.net/snown_by_constance.ntml
1.6024219359649171, 1.8822421959659072, 2286, 'http://gython-data.dr-chuck.net/snown_by_snown_ell.ntml')
8.1844194988893195, 8.4841019408899123, 199, 'http://gython-data.dr-chuck.net/snown_by_snown_ell.ntml')
3.085212427380309, 3.08521242730329, 307, 'http://gython-data.dr-chuck.net/snown_by_snown_ell.ntml')
3.085212427380309, 3.08521242730329, 307, 'http://gython-data.dr-chuck.net/snown_by_snown_ell.ntml')
3.085212427380309, 3.08521242738029, 307, 'http://gython-data.dr-chuck.net/snown_by_snown_ell.ntml')
3.085212427380309, 3.08521242738029, 307, 'http://gython-data.dr-chuck.net/snown_by_snown_ell.ntml')
3.085212427380309, 3.08521242723029, 307, 'http://gython-data.dr-chuck.net/snown_by_snown_ell.ntml')
3.085212427380309, 3.08521242723029, 307, 'http://gython-data.dr-chuck.net/snown_by_snown_ell.ntml')
3.085212427380309, 3.08521242723029, 307, 'http://gython-data.dr-chuck.net/snown_by_snown_ell.ntml')
3.085212427380309, 3.08521242723029, 307, 'http://gython-data.dr-chuck.net/snown_by_snown_ell.ntml')
3.085212427380309, 3.085212427380309, 307, 'http://gython-data.dr-chuck.net/snown_by_snown_ell.ntml')
 3.8852142730209, 3.8852142730209, 307, 'http://python-data.dr-chuck.net/known.by_Terry.html')
15.13028237907518, 15.1312823790514, 311, 'http://python-data.dr-chuck.net/known.by_Terry.html')
16.6091310439680915, 0.6091310439680912, 354, 'http://python-data.dr-chuck.net/known.by_Patricia.html')
1.95095226580653114, 1.509522658065301, 488, 'http://python-data.dr-chuck.net/known.by_Jing.html')
1.95095226580653114, 1.50962653792417, 507, 'http://python-data.dr-chuck.net/known.by_Jing.html')
1.95095270682537924811, 1.9696255379247, 507, 'http://python-data.dr-chuck.net/known.by_Jing.html')
1.938431274092393, 0.383706322785212, 353, 'http://python-data.dr-chuck.net/known.by_Jing.html')
1.938431274092393, 0.383706322785212, 353, 'http://python-data.dr-chuck.net/known.by_Jing.html')
1.638218037086303, 10.302386370853108, 505, 'http://python-data.dr-chuck.net/known.by_Jing.html')
1.638218037085123, 1.0382383129832408, 505, 'http://python-data.dr-chuck.net/known.by_Jing.html')
1.8382509371882197, 1.3382509371082198, 1238, 'http://python-data.dr-chuck.net/known.by_Lionna.html')
1.382509371882197, 1.382509371082198, 1238, 'http://python-data.dr-chuck.net/known.by_Lionna.html')
1.382509371882197, 1.3825809371082198, 1238, 'http://python-data.dr-chuck.net/known.by_Lionna.html')
1.382509371882197, 1.3825809371082198, 1238, 'http://python-data.dr-chuck.net/known.by_Lionna.html')
1.382509371882197, 1.3825809371082198, 1238, 'http://python-data.dr-chuck.net/known.by_Lionna.html')
1.382509371882197, 1.382580371082198, 1238, 'http://python-data.dr-chuck.net/known.by_Lionna.html')
     1.3626997/3082449, 1.38626997/3082499, 1238, http://python-data.dr-chuck.net/knoml_by_Chesp.html')
8.08997/308826943, 3.58997/3288269156, 1262, http://python-data.dr-chuck.net/knoml_by_Chesp.html')
9.02565434404678, 0.9256514340466692, 1529, http://python-data.dr-chuck.net/knom_by_Saiba.html')
1.189207/308194804, 1.191082788943848, 1559, http://python-data.dr-chuck.net/knom_by_Saiba.html')
1.510817490897222, 1.91081749097201, 1644, http://python-data.dr-chuck.net/knom_by_Saibano.html')
     1.30621/30699/1221, 1.736621/30699/1021, devi, http://python-data.dr-chuck.het/know_py_lizafoi.tml;
0.90591/3108918059, 0.995147/3469301802, 1842, 'http://python-data.dr-chuck.het/know_py_lizafoi.html')
0.9059792389923192, 0.995992289923127, 2449, 'http://python-data.dr-chuck.net/know_py_lizafoi.html')
1.32892346978699913, 1.33892445778387, 2689, 'http://python-data.dr-chuck.net/know_py_lizafoi.html')
1.32892346978699913, 1.33892345978659965, 3165, 'http://python-data.dr-chuck.net/know_py_ander.html')
1.3283246978699113, 1.3289246978699983, 3165, 'http://python-data.dr-chuck.net/known.by_knder.html')
2.65875223252858, 2.8557523225858, 2369, 'http://python-data.dr-chuck.net/known.by_fullor.html')
2.668746412542155, 2.64874641245273, 3324, 'http://python-data.dr-chuck.net/known.by_fullor.html')
8.6699724595084274, 8.6699724595884117, 20, 'http://python-data.dr-chuck.net/known.by_fullor.html')
8.6599324595084274, 8.6699724595884117, 20, 'http://python-data.dr-chuck.net/known.by_fullor.html')
8.659464660679185, 8.0534634660675187, 225, 'http://python-data.dr-chuck.net/known.by_fullor.html')
8.144796642381955, 9.3147966231935, 319, 'http://python-data.dr-chuck.net/known.by_fullor.html')
8.144786423893994, 8.1358238937893066, 639, 'http://python-data.dr-chuck.net/known.by_fullile.html')
9.2823981270656526, 8.282398122706566, 544, 'http://python-data.dr-chuck.net/known.by_fullile.html')
8.856854280812756 6.86854666753, 400, 'http://python-data.dr-chuck.net/known.by_fullile.html')
8.8568542808127056526, 8.282398122706566, 544, 'http://python-data.dr-chuck.net/known.by_fullile.html')
     0.8530121861453319, 0.8530121861453168, 841, 'http://python-data.dr-chuck.net/known_by_Forbes.html')
0.7377150405356286, 0.7377150405356301, 870, 'http://python-data.dr-chuck.net/known_by_Charlize.html')
     0.618371924941718, 0.6183719249417226, 887, 'http://python-data.dr-chuck.net/known_by_Shilpa.html')
1.7183690761606418, 1.7183690761606265, 1004, 'http://python-data.dr-chuck.net/known_by_Kalen.html'
     1.467526126929276, 1.4675261269292803, 1024, 'http://python-data.dr-chuck.net/known_by_Avinash.html')
0.2339474326191034, 0.23394743261909962, 1104, 'http://python-data.dr-chuck.net/known_by_Fatiha.html')
```

Prueba del PageRank para la URL https://www.javeriana.edu.co



Referencias y recursos adicionales

- https://www.py4e.com/html3/16-viz
- http://www.dr-chuck.com/
- https://www.youtube.com/playlist?list=PLIRFEj9H3Oj7Bp8-DfGpfAfDBiblRfl5p
- http://infolab.stanford.edu/~backrub/google.html
- https://d3js.org/
- https://github.com/d3/d3-force
- https://observablehq.com/@d3/force-directed-graph
- https://bl.ocks.org/mbostock/ad70335eeef6d167bc36fd3c04378048
- https://www.crummy.com/software/BeautifulSoup/bs4/doc/
- https://www.statisticshowto.datasciencecentral.com/absolute-error/



Acknowledgements / Contributions



These slides are Copyright 2010- Charles R. Severance (www.dr-chuck.com) of the University of Michigan School of Information and open.umich.edu and made available under a Creative Commons Attribution 4.0 License. Please maintain this last slide in all copies of the document to comply with the attribution requirements of the license. If you make a change, feel free to add your name and organization to the list of contributors on this page as you republish the materials.

Initial Development: Charles Severance, University of Michigan

School of Information





